实验4 K-Means聚类算法

小组成员: 张涵之@191220154 林芳麒@191220057

完成进度:基础+选做 100%

日期: 2022.5.30

一、实验内容

任务实现K - Means聚类算法

执行命令: hadoop jar KMeans.jar /data/2022s/kmeans/dataset.data/data/2022s/kmeans/initial_centers/user/2021sg07/KMeansOutput

自定义聚类中心 (p,1) 类 VectorBean

```
public class VectorBean implements Writable
{
    double[] vector = new double[15];//向量各分量
    int count = 0;//数据点个数n
    .....
}
```

(一) Map 和 Reduce 的设计思路

Мар:

输出 Key 类型为 IntWritable, Value 类型为 VectorBean (聚类中心向量 (p,1))

- 1.在 map 类的初始化方法 setup 中读取全局的聚类中心信息
- 2.对 map 方法收到的每一个数据点p,计算p与所有聚类中心间的距离,并选择一个距离最小的中心作为p所属的聚类,输出 <ClusterID, (p,1)>键值对。

Combine:

对每个 Map 节点上即将传递到 Reduce 节点的每一个 <ClusterID, (p,1)> 键值对,用 Combine 进行数据优化,合并相同 Cluster ID 下的所有数据点,并求这些点的均值 pm 以及数据点个数 n

Reducer:

输入 Key 类型为 IntWritable (ClusterID), 输入 Value 类型为 VectorBean (以 ClusterID 为分组的的 VectorBean 集合)。

输出 Key 类型为 Text, Value 类型为 NullWritable。

经过 Map 和 Combine 后从Map节点输出的所有 ClusterID 相同的中间结果 <Cluster ID, [(pm1, n1), (pm2, n2) ...]>, 计算新的均值pm, 输出 <ClusterID,pm>

所有输出的 <ClusterID, (pm,n)> 形成新的聚类中心, 供下一次迭代计算。

当连续两次的MapReduce结果相同,停止迭代,根据需要的精度输出结果。

(二) MapReduce 中 Map 和 Reduce 伪代码

```
/*
Mapper.java
*/
class Mapper{
 void setup(...)
    //读出全局的聚类中心数据 Centers
  }
 void map(key, p) // p为一个数据点
   minDis = Double.MAX VALUE;
   index = -1;
   for i=0 to Centers.length
      dis= ComputeDist(p, Centers[i]);
      if dis < minDis
       minDis = dis;
       index = i;
      }
    }
   emit(Centers[i].ClusterID, (p,1));
  }
}
```

```
/*
Combiner.java
*/
class Combiner {
  reduce(ClusterID, [(p1,1), (p2,1), ...])
  {
```

```
pm = 0.0;

n = 数据点列表[(p1,1), (p2,1), ...]中数据点的总个数;

for i=0 to n

pm += p[i];

pm = pm / n; // 求得这些数据点的平均值

emit(ClusterID, (pm, n));

}
```

(三)输出结果部分截图

HDFS上的路径: /user/2021sg07/KMeansOutput

File - /user/2021sg07/KMeansOutput/part...

- Page 1 of 1 ⋈ ✓ ▶ ⋈ 🥲
- 0 4.490,4.501,4.508,4.485,4.501,4.501,4.489,4.493,4.501,4.512,4.492,4.509,4.495,4.492,4.509
- 14.506,14.492,14.504,14.499,14.497,14.501,14.513,14.506,14.509,14.512,14.485,14.520,14.504,14.515,14.502
- 2 24.507,24.506,24.494,24.498,24.495,24.491,24.502,24.504,24.512,24.499,24.497,24.510,24.512,24.497,24.496
- 3 34.511,34.495,34.516,34.508,34.514,34.492,34.507,34.508,34.500,34.518,34.496,34.502,34.505,34.511,34.482
- 4 44.497,44.508,44.498,44.501,44.496,44.503,44.513,44.498,44.504,44.507,44.502,44.502,44.493,44.511,44.500
- 5 54.501,54.501,54.496,54.504,54.502,54.505,54.499,54.517,54.485,54.510,54.492,54.506,54.488,54.507,54.505
- 6 64.506,64.516,64.507,64.511,64.493,64.508,64.497,64.493,64.495,64.499,64.510,64.515,64.505,64.490,64.501
- 7 74.506,74.515,74.509,74.512,74.505,74.499,74.504,74.518,74.515,74.508,74.498,74.512,74.497,74.503,74.492
- 8 84.500,84.498,84.509,84.479,84.496,84.488,84.496,84.495,84.498,84.497,84.493,84.508,84.494,84.483,84.508
- 9 94.498,94.497,94.490,94.512,94.491,94.493,94.495,94.500,94.505,94.497,94.499,94.501,94.497

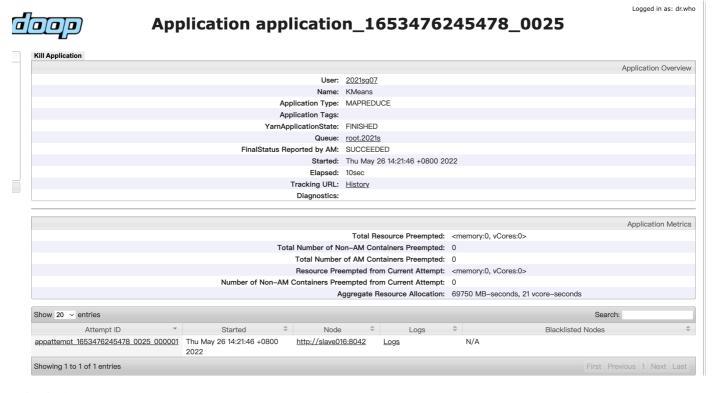
104.489, 104.498, 104.481, 104.521, 104.494, 104.498, 104.503, 104.491, 104.500, 104.489, 104.505, 104.512, 104.524, 104.509, 104.503

11

114 507 114 505 114 501 114 477 114 501 114 509 114 493 114 502 114 516 114 503 114 503 114 499 114 502 114 497 114 503

Cancel Download

(四) WebUI 执行报告



(五) 算法分析

局限性和不足:

- 1.对初始cluster centers的选取回影响到最终的聚类结果,因此只能得到局部最优解,不保证得到全局最优解。
- 2.相似度计算和比较时的计算量较大。
- 3.数据越大, 计算复杂度越高。

优化: 将各个点到cluster center相似度的计算工作分摊到不同的机器上并行地计算,从而大幅提高计算速度。

附加 不同聚类划分

执行命令: hadoop jar DivideCluster.jar /data/2022s/kmeans/dataset.data/user/2021sg07/KMeansOutput/part-m-00000 /user/2021sg07/ClusterOutput/

- 1.用基础任务的输出聚类中心作输入。
- 2.自定义向量对象 (index, p) 类 VectorBean

index 表示该向量条目的ID

p为一个向量的数据,是一个 double 集合

```
public class VectorBean implements Writable
{
    double[] vector = new double[15];
    int count = 0;
    .....
}
```

3.MultipleOutputs 类可以将数据写到多个文件,这些文件的名称源于输出的键和值或者任意字符串。这允许每个reducer(或者只有 map 作业的 mapper)创建多个文件。

(一) Map和Reduce设计思路

Map:

输出 Key 类型为 IntWritable, Value 类型为 VectorBean (向量对象 (index, p))

- 1.在 Map 类的初始化方法 setup() 中读取全局的聚类中心信息
- 2.对 map() 方法收到的每一个数据点p, 计算p与所有聚类中心间的距离, 并选择一个距离最小的中心作为p所属的聚类, 输出 <ClusterID, (index, p)>键值对。

Reducer:

输入 Key 类型为 IntWritable (ClusterID), 输入 Value 类型为 VectorBean (以 ClusterID 为分组的的 VectorBean 集合)。

输出 Key 类型为 NullWritable, Value 类型为 VectorBean。

- 1.在 Reduce 类的初始化方法 setup() 中新建 MultipleOutputs 对象
- 2.在 reduce 方法中,对从Map节点输出的所有 ClusterID 相同的结果 <Cluster ID, [(index1,p1), (index2,p2), ...]>,写入同一个文件。
- 3.在 cleanup 方法中,关闭当前输出结果文件。

(二) Map和Reduce的伪代码

```
/*
DivideMapper.java
class DivideMapper {
   void setup() {
     //读取全局的聚类中心信息
       centers = DivideUtils.readCenters(centerPath);
   }
   void map(key,p) {// p为一个数据点
       minDis = Double.MAX VALUE;
       index = -1;
       for i=0 to Centers.length
         dis= ComputeDist(p, Centers[i]);
         if dis < minDis
           minDis = dis;
           index = i;
         }
       }
       IntWritable clusterID = new IntWritable(index);//选择一个距离最小的中心作为p所属的聚
类
       VectorBean p = new VectorBean();
       p.setIndex(selfIndex);
       p.setVector(vectorDbl);
       context.write(clusterID, p);//输出<聚类中心ID, 向量对象>键值对
   }
}
```

```
/*
DivideReducer.java
*/
class DivideReducer{
    void setup() {
        mos = new MultipleOutputs(context);
    }

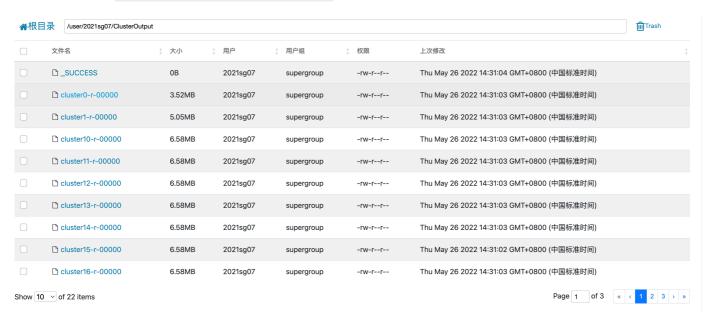
    void reduce(key,values) {}

    {
        String clusterID = "cluster" + key.toString();
        for (VectorBean vector : values) {
            mos.write(clusterID, NullWritable.get(), vector);
        }
}
```

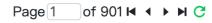
```
void cleanup() {
    mos.close();
}
```

(三)输出结果部分截图

HDFS输出路径: /user/2021sg07/ClusterOutput



File - /user/2021sg07/ClusterOutput/clust...



```
0: 5 5 9 5 3 7 4 8 7 4 9 9 3 6 9

1: 2 5 1 5 9 3 4 2 3 3 3 6 2 9 7

2: 0 9 3 8 3 6 0 8 5 9 3 4 6 3 2

3: 8 8 8 8 9 5 4 1 4 3 9 5 1 6 9

4: 1 4 6 0 2 8 3 2 6 4 2 7 7 7 8

5: 17 8 4 6 8 9 2 1 1 5 7 7 9 9

6: 8 7 0 6 7 3 2 7 6 6 6 0 0 8 6

7: 4 4 4 8 9 1 9 8 7 8 3 9 7 3 1

8: 4 9 1 5 2 0 7 0 1 0 3 5 8 2 8

9: 2 6 0 4 0 7 4 3 4 5 8 1 2 6 9

10: 5 5 2 9 5 7 1 2 7 4 1 9 6 3 7

11: 11 0 3 6 3 2 1 0 2 0 4 4 3 1

12: 4 9 0 2 7 5 1 0 5 8 8 4 1 9 8

13: 5 1 3 8 5 6 6 6 7 6 5 4 5 4 1

14: 6 5 9 4 7 4 7 9 1 9 4 4 1 8 7
```

(四) WebUI 执行报告

Showing 1 to 1 of 1 entries

Application application_1653476245478_0028

Logged in as: dr.who

First Previous 1 Next Last

