

大数据处理综合实验

复习大纲

南京大学计算机科学与技术系

主讲人：顾荣

课程鸣谢：

本课程得到Google公司、Intel公司中国大学合作部精品课程计划资助

本课程得到教育部产学合作协同育人项目（合作企业：字节跳动）的资助

Ch. 1. 并行计算技术简介

1. 为什么需要并行计算？

■ 提高计算机性能有哪些基本技术手段

- 提高字长，流水线微体系结构技术，提高集成度，提升主频

■ 迫切需要发展并行计算技术的主要原因

- 单处理器性能提升达到极限
- 应用规模和数据量急剧增大，超大的计算量/计算复杂度

2. 并行计算技术的分类

■ 有哪些主要的并行计算分类方法？

- 按数据和指令处理结构：弗林(Flynn)分类
- 按并行类型
- 按存储访问构架
- 按系统类型
- 按计算特征
- 按并行程序设计模型/方法

Ch. 1. 并行计算技术简介

3. 并行计算的主要技术问题

■ 并行计算有哪些方面的主要技术问题？

- 多核/多处理器网络互连结构技术
- 存储访问体系结构
- 分布式数据与文件管理
- 并行计算任务分解与算法设计
- 并行程序设计模型和方法
- 数据同步访问和通信控制
- 可靠性设计与容错技术
- 并行计算软件框架平台
- 系统性能评价和程序并行度评估

■ 如何评估程序的可并行度(掌握Amdahl定律的重要作用)

Ch. 1. 并行计算技术简介

4.MPI并程序序设计

- MPI功能与特点
- MPI程序结构
- MPI基本编程接口
- MPI编程实例

5.为什么需要大规模数据并行处理？

- 处理数据的能力大幅落后于数据增长
- 海量数据隐含着更准确的事实

■ 什么是MapReduce？

- 基于集群的高性能并行计算平台(Cluster Infrastructure)
- 并行程序开发与运行框架(Software Framework)
- 并行程序设计模型与方法(Programming Model & Methodology)

■ 为什么MapReduce如此重要？

- 高效的大规模数据处理方法
- 改变了大规模尺度上组织计算的方式
- 第一个不同于冯诺依曼结构的、基于集群而非单机的计算方式的重大突破
- 目前为止最为成功的基于大规模计算资源的并行计算抽象方法

Ch.2. MapReduce简介

1. 对付大数据处理-分而治之

- 大数据分而治之的并行化计算
- 大数据任务划分和并行计算模型

2. 构建抽象模型-Map和Reduce

- 主要设计思想：
为大数据处理过程中的两个主要处理操作提供一种抽象机制
- 典型的流式大数据问题的特征
- Map和Reduce操作的抽象描述
提供一种抽象机制，把做什么和怎么做分开，程序员仅需要描述做什么，不需要关心怎么做
- 基于Map和Reduce的并行计算模型和计算过程

Ch.2. MapReduce简介

3.上升到构架-自动并行化并隐藏底层细节

- 主要需求、目标 and 设计思想
 - 实现自动并行化计算
 - 为程序员隐藏系统层细节
- MapReduce提供统一的构架并完成以下的主要功能
 - 任务调度
 - 数据/代码互定位
 - 出错处理
 - 分布式数据存储与文件管理
 - Combiner和Partitioner（设计目的和作用）

4.MapReduce的主要设计思想和特征

- 向“外”横向扩展，而非向“上”纵向扩展
- 失效被认为是常态
- 把计算处理向数据迁移
- 顺序处理数据、避免随机访问数据
- 为应用开发者隐藏系统层细节
- 平滑无缝的可扩展性

Ch.3. Google /Hadoop MapReduce基本构架

1.MapReduce的基本模型和处理思想

2.Google MapReduce的基本工作原理

- Google MapReduce并行处理的基本过程
- 带宽优化（**Combiner**的设计目的和作用）
- 用数据分区解决数据相关性问题（**Partitioner**的设计目的和作用）
- 失效处理
- 计算优化

3.分布式文件系统GFS的基本工作原理

- Google GFS的基本设计原则
 - 廉价本地磁盘分布存储
 - 多数据自动备份解决可靠性
 - 为上层的MapReduce计算框架提供支撑
- Google GFS的基本构架和工作原理
 - GFS Master的主要作用
 - GFS ChunkServer的主要作用
 - 数据访问工作过程
 - GFS的系统管理技术

Ch.3. Google /Hadoop MapReduce基本构架

4.分布式结构化数据表BigTable

- BigTable的基本作用和设计思想
- BigTable设计动机和目标
 - 需要存储管理海量的结构化半结构化数据
 - 海量的服务请求
 - 商用数据库无法适用
- BigTable数据模型—多维表
 - 一个行关键字(row key)
 - 一个列关键字(column key)
 - 一个时间戳(time stamp)
- BigTable基本构架
 - 子表服务器
 - 子表存储结构SSTable（对应于GFS数据块）
 - 子表数据格式
 - 子表寻址

Ch.3. Google /Hadoop MapReduce基本构架

5.Hadoop 分布式文件系统HDFS

- HDFS的基本特征
- HDFS基本构架
 - NameNode的作用
 - DataNode的作用
- HDFS数据分布设计
- **HDFS可靠性与出错恢复**
- HDFS的安装和启动
- HDFS文件系统操作命令

6.Hadoop MapReduce的基本工作原理

- Hadoop MapReduce基本构架与工作过程
 - JobTracker的作用
 - TaskTracker的作用
 - **MapReduce作业执行过程**

Ch.3. Google /Hadoop MapReduce基本构架

6.Hadoop MapReduce的基本工作原理

- Hadoop MapReduce主要组件
 - 文件输入格式InputFormat
 - 输入数据分块InputSplits
 - 数据记录读入RecordReader
 - **Mapper**
 - **Combiner**
 - **Partitioner**
 - **Reducer**
 - 文件输出格式OutputFormat
- 容错处理与计算性能优化

7.Hadoop 分布式文件系统HDFS编程

- FileSystem基类
- 创建文件
- 打开文件
- 获取文件信息
- 获取目录信息
- 文件读取
- 文件写入
- 关闭
- 删除

Ch.4. Hadoop系统安装运行与程序开发

1.Hadoop安装方式

- 单机方式
- 单机伪分布方式
- 集群分布模式

2.单机Hadoop系统安装基本步骤

3.集群Hadoop系统安装基本步骤

4.Hadoop集群远程作业提交与执行

- 程序开发与提交作业基本过程
- 集群分布方式下远程提交作业

5.Hadoop MapReduce程序开发

Ch.5. MapReduce算法设计

1.MapReduce可解决哪些算法问题？

- 基本算法
- 复杂算法或应用

2.回顾：MapReduce流水线

3.MapReduce排序算法

4.MapReduce单词同现分析算法

5.MapReduce文档倒排索引算法

6.专利文献数据分析

Ch.6. HBase与Hive程序设计

1. HBase基本工作原理

- HBase的设计目标和功能特点
- HBase数据模型
- HBase的基本构架
- HBase的数据存储和管理

2. HBase基本操作与编程方法示例

- Hbase shell 操作
 - 创建表格与列举表格
 - 插入数据
 - 描述表信息
 - 输入数据与扫描数据
 - 限制列进行扫描
 - HBase中的disable和enable

Ch.6. HBase与Hive程序设计

2. HBase基本操作与编程方法示例

■ HBase的Java编程

- 创建表
- 删除表
- 查询数据
- 插入数据
- 删除数据
- 切分表

Ch.6. HBase与Hive程序设计

3. Hive基本工作原理

- 在Hadoop上用SQL进行数据分析
- Hive的组成模块
- Hive的系统结构
- Hive的数据模型
- 元数据存储：Metastore
- 数据的物理分布情况
- Hive系统的配置

Ch.6. HBase与Hive程序设计

4. Hive基本操作示例

- 启动Hive的命令行界面shell
- 创建数据表
- 装入数据
- SELECTS and FILTERS
- Group By
- Join

Ch.7. 高级MapReduce编程技术

1. 复合键值对的使用

- 用复合键让系统完成排序
- 把小的键值对合并成大的键值对

2. 用户自定义数据类型

- Hadoop内置的数据类型
- 用户自定义数据类型
 - 需要实现Writable接口
 - 作为key或者需要比较大小时则需要实现WritableComparable接口

3. 用户自定义输入输出格式

- Hadoop内置的文件输入格式
 - TextInputFormat
 - KeyValueTextInputFormat
- Hadoop内置的RecordReader
 - LineRecordReader
 - KeyValueLineRecordReader

Ch.7. 高级MapReduce编程技术

3. 用户自定义输入输出格式

- 用户自定义InputFormat和RecordReader的方法
 - *NewInputFormat* extends *FileInputFormat<Text, Text>*
 - *NewRecordReader* extends *RecordReader<Text, Text>*
 - `job.setInputFormatClass(NewInputFormat.class)`
- Hadoop内置的文件输出格式
 - **TextOutputFormat**
 - **KeyValueTextOutputFormat**
- Hadoop内置的RecordWriter
 - **LineRecordWriter**
- 用户自定义OutputFormat和RecordWriter的方法
 - *NewOutputFormat* extends *FileOutputFormat<Text, Text>*
 - *NewRecordWriter* extends *RecordWriter<Text, Text>*
 - `job.setOutputFormatClass(NewOutputFormat.class)`

Ch.7. 高级MapReduce编程技术

4. 用户自定义Partitioner和Combiner

■ 定制Partitioner

- Class **NewPartitioner** extends HashPartitioner<K,V>

```
{ // override the method
    getPartition(K key, V value, int numReduceTasks)
    { .....
    }
```

- Job. setPartitionerClass(NewPartitioner)

■ 定制Combiner

- public static class **NewCombiner** extends Reducer < Text, IntWritable, Text, IntWritable >

```
{ // 实现reduce方法
    public void reduce(Text key, Iterable<IntWritable> values, Context context)
        throws IOException, InterruptedException
    { ...
    }
```

- Job. setCombinerClass(NewCombiner)

特别注意: **Combiner**输出时不能改变其输入键值对的格式, 必须保持一致!

思考题: 请同学们解释为什么要有这个要求? 如果不转手这个要求会发生什么问题?

Ch.7. 高级MapReduce编程技术

5. 多数据源的连接

■ 用DataJoin类实现Reduce端Join

- 连接主键GroupKey与记录标签Tag
- DataJoinMapperBase
- DataJoinReducerBase
- TaggedMapOutput
- Mapper需要实现的抽象方法
 - `abstract Text generateInputTag(String inputFile)`
 - `abstract TaggedMapOutput generateTaggedMapOutput(Object value)`

Ch.7. 高级MapReduce编程技术

5. 多数据源的连接

■ 用文件复制实现Map端Join

用distributed cache将一个或多个小数据量文件分布复制到所有节点上

- Job类中：`public void addCacheFile(URI uri)`
将一个文件放到distributed cache file中
- Mapper或Reducer的context类中：
`public Path[] getLocalCacheFiles()`
获取设置在distributed cache files中的文件路径
- Replicated Joins方法的变化使用
- 带Map端过滤的Reduce端Join
- 多数据源连接解决方法的限制

6. 全局参数/数据文件的传递

■ 全局作业参数的传递

- Configuration类专门提供以下用于保存和获取属性的方法
- mapper/reducer类初始化方法`setup()`从configuration对象中读出属性

■ 全局数据文件的传递(见上distributed cache的使用)

Ch.7. 高级MapReduce编程技术

7.其它处理技术

- 查询任务相关信息
- 划分多个输出文件集合
- 输入输出到关系数据库
- 从数据库中输入数据
 - DBInputFormat: 提供从数据库读取数据的格式
 - DBRecordReader: 提供读取数据记录的接口
- 向数据库中输出计算结果
 - DBOutputFormat: 提供向数据库输出数据的格式
 - DBRecordWriter: 提供向数据库写入数据记录的接口
 - DBConfiguration提供数据库配置和创建连接的接口
 - 创建数据库连接: `public static void configureDB`
(Job job, String driverClass, String dbUrl, String userName, String passwd)
 - 指定写入的数据表和字段: `public static void setOutput`
(Job job, String tableName, String... fieldNames)

Ch.8. 基于MapReduce的搜索引擎算法

1. 网页排名图算法PageRank

- PageRank的基本设计思想和设计原则
- PageRank的简化模型及其缺陷
- PageRank的随机浏览模型
- 随机浏览模型的PageRank公式
- 用MapReduce实现PageRank
 - Phase1: GraphBuilder
 - Phase2: PageRankIter
 - Phase3: Rankviewer
 - PageRank迭代终止条件

2. 全文搜索引擎算法的设计实现

- 离线Web文档倒排索引处理
- 基于倒排索引实现在线全文检索

Ch.9 基于MapReduce的数据挖掘基础算法

1. 基于MapReduce的K-Means并行化算法

- 数据挖掘并行算法研究的重要性
- K-Means聚类算法
- 基于MapReduce的K-Means并行算法设计
- 聚类算法应用实例

2. 基于MapReduce的分类并行化算法

- 分类问题的基本描述
- K-最近邻分类并行化算法
- 朴素贝叶斯分类并行化算法

Ch.9 基于MapReduce的数据挖掘基础算法

3. 基于MapReduce的频繁项集挖掘算法

- 频繁项集挖掘基本问题
- 现有算法概述
- PSON：基于MapReduce的并行化算法
- 并行化算法实验结果

Ch.10 Spark系统及其编程技术

1. Spark系统简介

■ 为什么会有Spark?

■ Spark的基本构架和组件


- Master node + Driver
- Worker node + Executors

■ Spark的程序执行过程

- Application(Driver+Executor), Job, Stage, Task

■ Spark的技术特点

- 基于内存计算的弹性分布式数据集(RDD)
- 灵活的计算流图(DAG)
- 覆盖多种计算模式(查询分析, 批处理, 流式计算, 迭代计算, 图计算, 内存计算)



Ch.10 Spark系统及其编程技术

1. Spark系统简介

■ Spark编程模型与编程接口

- RDD Transformation & Action
- Scala, Java, Python

■ Spark的安装运行模式

- Standard-Alone, YARN, MESOS, Docker

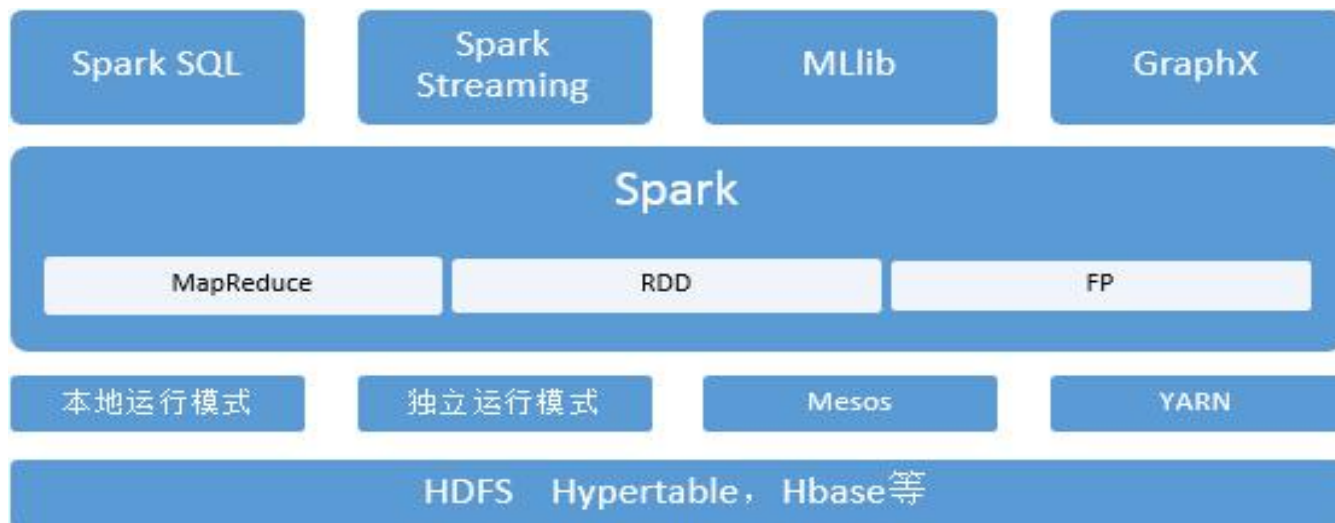
Ch.10 Spark系统及其编程技术

2. Spark编程

- WordCount
- KMeans

3. Spark环境中其它功能组件简介

- Spark SQL
- Spark Streaming
- GraphX
- MLlib



Thanks !